

Especificação do trabalho de IA

O trabalho de Inteligência Artificial versa sobre a rede neural artificial Multilayer Perceptron (MLP), a rede neural artificial Convolutional Neural Network (CNN) e abrange a prática com modelagem, implementação, testes e análise de resultados. Observe as regras abaixo e na sequência, verifique os objetivos do trabalho e mais detalhes sobre como devem ser as implementações e entregas.

Algumas regras gerais

- Os alunos devem se organizar em grupos de até **seis** integrantes.
- Todas as entregas deverão ser feitas via Sistema e-Disciplinas, dentro da data limite estabelecida neste documento (e no syllabus).
 - Qualquer eventual problema com o sistema e-Disciplina deve ser observado com antecedência suficiente para que alguma solução de contorno possa ser estabelecida em conjunto com a professora. Isso significa que o grupo não deve deixar para fazer *upload* de arquivos no último minuto possível. Preferencialmente, o *upload* deve ser feito com uma antecedência mínima de um dia. O último dia de entrega deve ser deixado para *upload* de arquivos que representam apenas ajustes finos no trabalho.
- O grupo deverá produzir dois vídeos, com conteúdo referente a requisitos detalhados abaixo. **Cada aluno do grupo deve participar de pelo menos um dos dois vídeos**, explicando algum aspecto do trabalho tratado no vídeo. Uma janela com a imagem do aluno realizando a explicação deverá fazer parte dos vídeos.
- Para cada vídeo será disponibilizado no e-disciplina um roteiro que deverá ser seguido. A ordem dos itens do roteiro **NÃO** deve ser alterada. Será fornecido um modelo de slides para ser usado pelo grupo e esse modelo **NÃO** deve ser alterado. Será permitida a adição de slides extras, se for necessário, para acomodar algum conteúdo não previsto no modelo e que o grupo achar importante acrescentar.
- O grupo deverá preencher um **checklist** de conceitos obrigatórios implementados e testados no seu trabalho. Para cada conceito obrigatório, o grupo deve indicar em qual arquivo de código o conceito está implementado, bem como as linhas de código principais que devem ser analisadas para verificação da implementação.
- O grupo deverá preencher um **checklist** de conceitos opcionais implementados e testados no seu trabalho. Para cada conceito opcional implementado, o grupo deve indicar em qual arquivo de código o conceito está implementado, bem como as linhas de código principais que devem ser analisadas para verificação da implementação.
- Os códigos desenvolvidos pelo grupo deverão ser postados no sistema e-disciplinas.
- Os artefatos entregues (código, vídeos, slides, pdfs) deverão conter o **nome e número USP de todos os integrantes do grupo**.
- **Todos os artefatos devem ser cuidadosamente construídos, com boa estética de apresentação.** Artefatos apresentados com desmazelo/desleixo e de forma

negligente poderão implicar em desconto de nota ou atribuição de nota 0 ao artefato.

- **IMPORTANTE:** o tempo de vídeo é um critério de estabelecimento de avaliação igualitária entre os alunos, ou seja, vídeos “acelerados” implicarão em descontos na nota, podendo inclusive ser um fator determinante para a atribuição de nota 0 (zero) para esse quesito do trabalho. Uma possibilidade pode ser acelerar o vídeo enquanto mostra a execução de um treinamento, **mas a gravação da voz deve estar em velocidade normal.**
- **IMPORTANTE:** você pode disponibilizar o seu vídeo em qualquer repositório público ou no sistema e-Disciplinas. **Se você disponibilizar em um repositório público** (e não no sistema e-Disciplinas) você deverá depositar no sistema e-Disciplinas, até a data limite de entrega do trabalho, um arquivo **.pdf** com o link para o arquivo público e a minutagem do seu vídeo (com minuto de início e de fim para cada trecho de sua explicação), considerando os requisitos importantes de conteúdo solicitado para aquele vídeo.
- **Você NÃO deve depositar arquivos no e-disciplinas que não tenham sido solicitados – essa prática gera ruído para o trabalho de avaliação dos trabalhos.**
- Data limite para a postagem dos arquivos do trabalho: **25 de novembro até 23h55**

Requisitos para o vídeo 1 (MLP): o objetivo do vídeo 1 é propiciar a avaliação das implementações da rede neural artificial MLP em termos de seu funcionamento.

- Tempo de vídeo: mínimo de 5 minutos e máximo de 20 minutos.
- Conteúdo: ilustração da execução dos códigos para:
 - Treinamento da MLP para o conjunto de dados CARACTERES COMPLETO (os conjuntos de portas lógicas e o conjunto CARACTERES da Fausett servirão apenas para teste de implementação, então não precisam entrar nos vídeos).
 - Teste da MLP para o conjunto de dados CARACTERES COMPLETO.
- Detalhes importantes que devem ser comentados no vídeo:
 - Que parte dos conjuntos de dados está sendo usada para treinamento.
 - Que parte dos conjuntos de dados está sendo usada para validação **(quando for o caso)**.
 - Que parte dos conjuntos de dados está sendo usada para teste.
 - Apresentação do console (ou de um elemento de interface gráfica) para um acompanhamento, ainda que resumido (ou seja, parte da execução), do treinamento da rede MLP.
 - Apresentação do resultado da rede MLP, no console (ou um elemento de interface gráfica), para os dados de teste.
 - Apresentação da matriz de confusão resultante do teste das redes.
- Outros detalhes que o grupo considerar importantes para agregar valor ao seu trabalho podem ser inseridos desde que se mantenham dentro do tempo máximo de vídeo.

Requisitos para o vídeo 2 (CNN): o objetivo do vídeo 2 é propiciar a avaliação das implementações da rede neural artificial CNN em termos de seu funcionamento.

- Tempo de vídeo: mínimo de 5 minutos e máximo de 20 minutos
- Conteúdo - apresentação de como os seguintes conceitos foram implementados no código (variáveis e procedimentos):
 - Modelagem das entradas da CNN.
 - Camadas de aplicação de kernel e pooling, com detalhamento sobre o kernel e pooling aplicados.
 - Modelagem das camadas densas e camada de saída.
 - Lógica do treinamento da estrutura completa.
 - Teste da CNN para o conjunto de dados Fashion MNIST.
 - Apresentação da matriz de confusão resultante do teste das redes.
- Outros detalhes que o grupo considerar importantes para agregar valor ao seu trabalho podem ser inseridos desde que se mantenham dentro do tempo máximo de vídeo.

Objetivo 1: Multilayer Perceptron

Implementar uma rede neural artificial Multilayer Perceptron (MLP) - sem fazer uso de bibliotecas especializadas em redes neurais artificiais - com **uma** camada escondida e treinada com o algoritmo **Backpropagation em sua versão de Gradiente Descendente** – algoritmo de treinamento **discutido em sala de aula**.

Quatro **conjuntos de dados** devem ser usados para treinamento e teste:

- Conjuntos de dados OR, AND e XOR (para testes rápidos de corretude de implementação)
- Conjunto de dados CARACTERES (para aproximação do grupo com o processo de treinamento)
- Conjunto de dados CARACTERES COMPLETO (similar ao conjunto visto em aula)
 - O conjunto CARACTERES COMPLETO possui a versão limpa e as versões com ruídos. As versões com ruído são adequadas para usar nos testes.

Nos problemas de portas lógicas, a última coluna é o rótulo do dado, as demais são atributos descritivos. No problema dos caracteres, as últimas colunas compõem o rótulo (eventualmente, o grupo pode testar formas diferentes de trabalhar com composição de valores para construir o rótulo).

Arquivos de saída úteis para o seu trabalho:

- Um arquivo contendo os hiperparâmetros finais da arquitetura da rede neural e hiperparâmetros de inicialização.
- Um arquivo contendo os pesos iniciais da rede.
- Um arquivo contendo os pesos finais da rede.
- Um arquivo contendo o erro cometido pela rede neural em cada iteração do treinamento.
- Um arquivo contendo as saídas produzidas pela rede neural para cada um dos dados de teste realizados

Algumas regras referentes ao “objetivo 1”

- As implementações deverão ser feitas em linguagens baseadas em Java, C (e variações) ou Python.
- O código deve ser sempre muito bem documentado (em DETALHES) de forma que seja simples identificar passagens do código que são importantes para a verificação do entendimento do grupo sobre a lógica que implementa uma rede neural artificial. Isso significa que o uso de alguma biblioteca que implementa as funções de uma rede neural artificial pode se tornar extremamente complexo (você terá que explicar em detalhes o código da biblioteca, e por vezes, isso pode ser mais trabalhoso do que fazer o seu próprio código). Os comentários devem seguir a nomenclatura utilizada em sala de aula e no material de estudo indicado
- Bibliotecas que implementem funções de I/O, operações de matrizes e funções de PLOT podem ser livremente usadas para implementar entrada de dados e interface para exposição de resultados (a interface pode ser construída em modo gráfico, modo texto ou apenas com uso de prompt e gravação das saídas do algoritmo em arquivos .txt ou .csv).

Objetivo 2: Convolution Neural Network

Implementar uma rede neural artificial Convolution Neural Network (CNN) – aqui você pode fazer uso de bibliotecas especializadas em redes neurais artificiais - com várias camadas escondidas e camada densa ao final da estrutura.

- Você pode usar qualquer método de otimização da rede e quaisquer funções kernel ou de ativação e métodos de pooling. Porém, você precisa saber qual está usando e informações sobre esses métodos e funções que possam ter guiado suas escolhas. O entendimento profundo sobre os métodos e funções não é necessário neste trabalho, mas o conhecimento de suas características básicas sim.

O conjunto de dados escolhido deve ser usado para teste da rede neural, considerando duas tarefas:

- Uma tarefa multiclasse, ou seja, é esperado que a rede neural saiba responder corretamente para todas as classes do conjunto.
- Uma tarefa de classificação binária, ou seja, apenas duas classes, ou duas composições de várias classes, devem ser usados no treinamento e a rede deverá reconhecer essas duas classes. Você pode variar os pares de classes em seus testes. Você cria o seu ambiente de experimentação de teste em relação aos dados, ou seja, você escolhe como serão compostos os dados de treinamento e teste de suas duas classes.
- **O conjunto de dados é o Fashion MNIST**

A implementação da CNN deve ser feita com um framework à escolha do grupo.

O grupo pode testar sua implementação usando os dados em sua forma bruta ou então usando características extraídas dos dados (por exemplo, usando descritor HOG - *Histogram of Oriented Gradients*, LBP – *Local Binary Patterns*, Histograma de Blocos ou a transformada *wavelet* de Haar). O grupo deve obrigatoriamente apresentar uma das duas formas de trabalho. Apresentar as duas é benéfico para a avaliação do trabalho do grupo. A extração do descritor HOG ou qualquer outro descritor deve ser feita com uso de bibliotecas especializadas para garantir a corretude do resultado.

Arquivos de saída úteis para o seu trabalho:

- Um arquivo contendo os hiperparâmetros da arquitetura da rede neural e hiperparâmetros de inicialização.
- Um arquivo contendo os pesos iniciais da rede.
- Um arquivo contendo os pesos finais da rede.
- Um arquivo contendo o erro cometido pela rede neural em cada iteração do treinamento.
- Um arquivo contendo as saídas produzidas pela rede neural para cada um dos dados de teste.

Bibliotecas para manipulação de imagens (onde estão implementados os descritores):

- OpenCV: *Open Source Computer Vision*, disponível em <http://opencv.org/>, com interfaces para C++, C, Python, Java e MATLAB, sobre Windows, Linux, Mac OS e Android.
- scikit-image: disponível em <http://scikit-image.org/>, com interface para Python. Os responsáveis pedem gentilmente para que o uso da biblioteca seja citado. <http://dx.doi.org/10.7717/peerj.453>.
- MATLAB possui um pacote com funções úteis em processamento de imagens: *Computer Vision System Toolbox*.